

게임 시나리오 라이팅을 위한 AI모델 탐색과 비교

차현민[○], 서범주, 강신진

홍익대학교 게임학부

mirminescm@gmail.com, bseo@hongik.ac.kr, directx@hongik.ac.kr

A Comparative Study on AI Models for Game Scenario Writing

Hyeon-min Cha[○], Beom-joo Seo, Shin-jin Kang

School of Games, Hongik University

요 약

본 논문은 게임 시나리오 및 기획에 있어, 사용 모델을 사용할 수 없는 개발 기업들의 데이터 보안 문제를 오픈 소스 모델과 지식 증류를 활용하여, 서사 정보 추출 방법론을 제안하고, 이를 실험적으로 적용한 후 평가한다. 1930년대 한국 소설데이터를 기반으로 상용 모델(Claude 3.5 Haiku)을 활용해 인물, 사건, 장소에 대한 추출 정답지를 데이터셋으로 구축하고, 이를 오픈 소스 모델(Gemma4)에 LoRA 기법으로 학습시킨 후, 정량적 분석 결과, 지정된 포맷을 유지하는 스키마 준수율은 100%로 개선되고, 추출 정확도(F1-Score)는 0.1739에서 0.5124로 약 3배 향상되었다. 학습된 LoRA만으로도 추출 일관성과 정확도가 상당 부분 개선되는 것으로 보이며, 이러한 방법론을 사용한 모델을 통한 시나리오 라이팅 보조 프로그램을 통해 캐릭터 서사의 개선 가능성을 시사한다.

1. 서 론

2000년대 초반 한국 게임 산업에서 시나리오는 부수적인 요소로 치부되는 경향이 있었다. 그러나 2005년 ‘월드 오브 워크래프트(WoW)’의 흥행 이후, 캐릭터 마케팅이 게임의 수익성과 직결되면서 ‘매력적인 캐릭터 디자인’은 산업계의 핵심 과제로 부상하였다. 캐릭터의 매력을 결정짓는 요소에는 외형과 성능 등 다양한 변수가 존재하나, 최근 유저들은 캐릭터가 지닌 ‘서사(Narrative)’의 깊이에 주목하기 시작했다.

게임 개발에서 서사의 중요성은 증대되었으나, 실질적인 구현에는 여전히 한계가 존재한다. 많은 게임이 서사를 단순 설정 파트로 사용하거나, 단순히 신규 캐릭터 출시를 위한 단편적인 도구로 소비하며 사건 간의 인과관계나 구체적인 묘사가 결여되는 양상을 보인다. 본 연구자는 그 원인을 두 가지로 분석한다. 첫째는 전문 인력 관리의 어려움

이며, 둘째는 서사 자체가 지닌 추상성이다. 전문 작가군이 유입되면서 인력 수급 문제는 완화되고 있으나, 서사는 창작자의 주관적 상상력에 의존하는 추상적 개념이기에 공동 작업 시 일관성을 유지하기 어렵고 휴먼 에러가 빈번히 발생한다. 이러한 관리의 어려움을 해소하고 시나리오의 완결성을 높이기 위해 최근 AI를 활용하는 방법론들이 부상하고 있다.

현재 Gemini, Claude, GPT와 같은 거대 상용 언어 모델의 서사 분석 및 생성 능력은 비약적인 수준에 도달했다. 그러나 실제 게임 개발 현장에서 미공개 스토리나 핵심 설정 등 기업의 핵심 지식 재산권을 외부 상용 API의 프롬프트로 입력하는 것은 보안 및 데이터 유출 위험으로 인해 기업 입장에서 사실상 불가능하다. 따라서 보안이 보장된 온프레미스(On-premise) 환경에서 구동 가능한 오픈소스 기반의 AI 모델 활용이 필수적이다. 이에 본 연구는 오픈소스 모델인 Gemma를 베이스라인

으로 설정하여, 한국어 소설 데이터를 바탕으로 인물, 플롯, 장소 및 하위 특성을 추출하는 서사 분석 성능을 상용 모델과 비교 분석한다. 나아가, 상대적으로 부족할 수 있는 오픈소스 모델의 성능적 한계를 LoRA 파인튜닝 기법을 통해 실제 게임 시나리오 라이팅 보조에 적합한 수준으로 개선할 수 있는지 프로그램 개발에 앞선 실험적 학습으로 그 가능성을 검증하고자 한다.

2. 관련 연구

초기 언어 모델의 게임 적용은 일반적인 npc 페르소나와 그에 따른 비맥락적 대사와 같은 단순 텍스트 생성에 그쳤으나, 최근에는 긴 텍스트에서 발생하는 환각 현상을 극복하기 위해 서사 요소를 구조화된 데이터로 추출하는 연구가 주를 이룬다. 특히 복잡한 시대적 배경과 문맥이 포함된 텍스트에서 프롬프트 엔지니어링을 통해 정보를 정확히 추출하는 방법론의 유효성은 최근 연구들 [1], [2]를 통해 입증되었다.

거대 상용 모델은 이러한 서사 분석에 뛰어난 성능을 보이나, 게임의 핵심 지식 재산권을 외부 서버로 전송해야 하는 보안 리스크가 치명적이다. 이를 해결하고자 내부망 구동이 가능한 경량 오픈소스 모델의 활용이 제기되었으나 [3], 복잡한 소설 텍스트 분석과 정형화된 출력 양식(JSON 등) 유지에 있어서는 여전히 뚜렷한 한계를 보였다 [4].

이러한 성능 한계를 극복하기 위해, 고성능 상용 모델의 결과물을 정답으로 삼아 가벼운 모델을 학습시키는 지식 증류 기법이 새로운 방향으로 떠올랐다 [5]. 나아가 컴퓨팅 비용과 과적합 문제를 해결하기 위해 LoRA를 결합하여, 적은 자원으로도 상용 모델에 준하는 추론 능력과 양식 준수율을 확보하는 연구가 활발히 진행 중이다 [6].

본 연구는 이러한 최신 기술적 흐름을 실무 시나리오 라이팅에 접목한다. 상용 모델(Claude Haiku)을 활용해 1930년대 근대 소설 기반의 분석 정답지를 구축하고, 이를 지식 증류 및 LoRA 기법으로 오픈소스 모델(Gemma 4)에 학습시켜

상용 모델이 아닌 로컬 환경에서의 실질적인 성능 개선도를 확인한다.

3. 방법론

3.1 정답 데이터 추출 및 구조화

제안된 방법론을 검증하기 위하여, 상용 모델을 통하여 정답 데이터셋을 생성하기 위해 HuggingFace의 1930년대 소설 데이터셋에서 2,000개의 스토리 데이터를 선별하여 Claude 3.5 Haiku API를 사용하여 원문에서 인물, 사건, 장소에 대한 데이터를 추출하도록 프롬프트를 설계하였으며, 각 요소와 하위 요소들을 자율 생성하도록 유도하였다. 후속 파인 튜닝 및 설계 중인 시나리오 작성 보조 프로그램과의 연계를 위하여 출력은 JSON 포맷으로 강제하였다.

3.2 생성 데이터셋 분석

추출된 데이터들은 다시 한번 Key-Value 형태로 재가공하였다. 명시적 지시어와 출력 포맷 스키마를 Instruction 지정하였고, 소설 원문을 Input, 결과를 Output으로 매핑하였다. 환각 현상이 전이되는 것을 방지하기 위해, 파싱 오류 및 중복 데이터를 필터링한 결과, 2,000개의 초기 데이터 중 29%가 배제되고, 최종적으로 1,419개 5,681,000개의 토큰으로 구성된 학습 샘플을 확보했다.

해당 데이터셋 내부의 추출 요소들의 종류들을 분석한 결과, 인물 개체의 요소들이 많이 추출된 것을 확인하였고, 그 뒤를 사건, 제일 적게 추출된 것은 장소였다. 이는 1930년대 소설 텍스트가 인물 중심의 서사 구조를 가지고 있음을 감안하여야 하는 결과이다. 지정된 JSON 포맷되고 하위 요소들 역시 인물, 사건 중심으로 추출되었다.

3.3 LoRA 생성

LoRA 학습에 사용한 로컬 환경은 다음과 같다.

복잡한 서사 구조 학습 및 JSON 포맷 구조 학습을 위해 LoRA Rank 32, Alpha 64로 설정하여 모든 Linear 레이어에 높은 수치의 가중치를 적용했다. 또한 VRAM 메모리가 충분한 사양이 아니므로, 메모리 부족 현상을 이유로한 학습 중지 사태를 미연에 방지하기 위하여 실질 배치 사이즈를 8로 지정하고, Adam Optimizer를 적용해 학습률 2e-4로 총 4에포크 학습을 수행하였다. 학습 중 초기 Loss는 1.84였으며, 이후 0.72까지 안정적으로 감소하는 형태를 보였으며, 토큰 예측 정확도는 최종 85.27%를 달성했다. 시간당 처리량은 배치사이즈 기준 0.199 sample/sec으로 확인되었다.

3.4 LoRA 사용 데이터 생성 및 비교

생성된 LoRA를 접목한 파인튜닝 후 모델과 기존 모델을 동일한 데이터셋으로 데이터 추출을 진행했다. 다만, 원본 모델의 추출속도와 파인튜닝된 모델의 추출 속도가 상이하여, 원본 모델은 정답지로 사용된 상용 모델과 같은 양을 추출하였으나, 파인 튜닝된 모델은 약 200개의 데이터만을 추출하였다. 그 비교 수치는 아래와 같다.

예측대로 포맷을 강조하여 LoRANK를 레이어들에 대해 높은 가중치로 설정한 결과 스키마 준수율은 매우 높은 수치로 개선이 되었고, 추출 정확도도 3배 개선이 되었으며, 세부 요소 추출 개수 역시 약 2배 증가하여 서사적 분석 능력이 유의미하게 상승했음을 확인할 수 있었다.

분류	Claude 3.5	Gemma Base	Gemma SFT
인물 평균 추출 개수	3.2개	1.8개	4.1개
사건 평균 추출 개수	1.5개	0.4개	1.2개
장소 평균 추출	1.8개	1.1개	1.4개

개수 개체당 평균 속성 수	3.83개	1.60개	3.53개
-------------------------	-------	-------	-------

위 <표 1>의 분석 결과, 스토리 하나당 전체 평균 추출 개체 수는 정답 모델 6.5개, 원본 모델 3.3개, 파인튜닝 모델 6.7개로 나타났다. 또한, 개체당 추출되는 평균 세부 요소를 뜻하는 정보 밀도는 1.60개에서 3.53개로 약 2.2배 향상되었다. 특히 원본 모델에서 원문에 없는 내용을 지어내거나 JSON 양식을 이탈하는 환각 비율이 47%에 달했으나, 파인튜닝 후에는 해당 수치가 0%에 수렴했다.

4. 논 의

방법론 검증은 사용 모델 선정, 데이터 셋 선정, 정답 데이터 셋 생성, 정답지를 기반으로한 LoRA 생성, 모델별 데이터 추출 실험, 비교로 진행되었다. 그리고 이 방법론의 실용성 검증을 위해서 파인튜닝 전후 모델의 정량적 지표를 분석한 결과, 유의미한 성능 변화를 확인함과 동시에 후속 실험에서 개선해야할 한계점들을 찾을 수 있었다.

첫째, 정량적 지표 해석이다. 실험 결과, 4B 규모의 소형 모델임에도 불구하고, LoRA 학습을 거친 후 포맷 준수율이 100%로 상승하였고, 추출 정확도는 약 3배로 향상되었다. 환각 비율은 47%에서 0%까지 감소하여 억제의 형태를 보였다. 이는 상용 모델에서 보이는 데이터 구조화 능력과 서사 분석 능력을 LoRA를 사용함으로써 소형 로컬 모델에도 이식할 수 있다는 점을 보여준다. 이를 통하여 목표했던 로컬 모델을 사용함으로써 상용 모델 사용 위험성을 기업이 감수하지 않을 수 있다는 가능성을 시사한다.

둘째, 서사 분석 능력의 향상이다. <표1>에서 나타나듯 파인 튜닝된 모델이 정답셋인 상용 모델보다 더 높은 빈도로 인물 요소를 추출 해냈다. 개체 당 평균 요소 수 역시 1.6개에서 3.53개로 두 배 이상의 상승 폭을 보이며, 서사 구조에서 현실감과 깊이를 더해주는 디테일한 분석 능력을 확보했다.

셋째, 추론 속도와 품질 간의 상충 관계이다. 앞선 실험 과정에서 온전한 포맷과 긴 설명을 출력해내기 위하여, 생성 토큰 길이를 512->1024로 증가 시킨 상황이었다. 이때, 추출 성공률이 급증하였으나, 생성에 걸리는 시간이 평균 1분 40초->5분으로 급증하는 현상이 발견되었다. 이는 로컬 모델 운용 환경에서 앞으로 개선해 나가야 할 방향을 보여주는 지표로 확인된다.

5. 결론

본 논문은 게임 시나리오 기획 시 발생하는 휴먼 에러 문제, 지식재산권 유출 문제를 해결하는 방법을 탐색하고자, 로컬 모델을 통한 서사 추출 방법론을 제안하고, 그 성능을 검증해보았다. 1930년대의 소설 데이터셋을 상용 모델로 분석하여 정답 데이터셋을 구축하고, 이를 로컬 모델과 LoRA기법으로 학습 시킨 결과, 포맷 준수율 100% 및 정확도 상승, 환각 비율 감소라는 지표를 확인할 수 있었다. 이를 통해 로컬 모델을 통한 게임 기획 시나리오 작성 보조 AI 보조 프로그램으로 더 적은 인력으로 효율적인 개발 프로세스를 구상해 볼 수 있을 것이다.

그러나 본 실험은 한계점도 분명히 존재한다.

1. 데이터셋의 절대적 수 부족

사용된 데이터셋은 1930년대의 소설 데이터셋 뿐이다. 이는 근대 소설만을 포함하고 있기에, 현대와 소설 배경, 플롯 구성 등이 상이하게 다를 것이 확실하고 이를 AI가 완벽히 해석하여 비슷한 수준의 결과물을 내놓을 수 있을 거라는 확신은 없다는 것이다. 따라서 차후 실험에서는 보다 다양한 데이터셋을 기용하여 보편적인 평가 기준 및 결론을 내는 것이 필요할 것이다.

2. 사용 모델의 종류 및 중대형 모델 미실험

실험에 사용된 모델은 상용 모델은 Claude3.5-Haiku, Gemma4:4b 모델 뿐이다. 해당 모델들은 각각 상용, 로컬 모델 중에서도 소형 모델에 속하는 분류이다. 더 상위의 Sonnet 모델,

Gemini 3.0 Pro 모델이나, 로컬 모델 중에서는 더 높은 토큰수를 지니는 26b 모델 등을 사용하여 실험에 임한다면 더 수준 높은 결과를 얻을 수 있지 않았을까 감히 예상한다.

3. 최종 평가 표본의 통계적 의미 부족

최종 표본으로 사용된 파인 튜닝된 모델에서 나온 결과값의 토큰 수는 기존 다른 모델들이 추출한 토큰량의 1/10뿐이다. 이는 다양한 서사구조에서 발생할 수 있는 환각 현상이나, 수치적인 부분에서 엄밀히 말하자면 부족한 수치이므로, 차후 실험에서는 규모를 키워 통계적 유의성을 충분히 보완해야 할 것이다.

결론적으로, 제한된 자원 안에서 실험한 결과, 이러한 환경에서도 지원되는 데이터셋의 품질이 확실하다면 소형 로컬 모델에서도 유의미한 서사 분석 능력을 가진 모델을 만들어낼 수 있다는 가능성을 확인했으며, 나아가 차후 실험에서는 더 다양한 모델과 데이터셋으로, 해당 논문에서 다루어 어느정도 검증해낸 파이프라인을 더 개선해내어 캐릭터 서사를 더 완결성있게 생성, 분석해내고 실무 현장에 광범위하게 적용될 수 있는 시나리오 작성 보조 프로그램을 개발하고자 한다.

Acknowledgement

This work was supported by 2026 Hongik University Innovation Support program Fund.

6. 참고 문헌

- [1] Author, A. et al., "Fine-Tuned LLMs are "Time Capsules" for Tracking Societal Bias Through Books", arXiv:2502.05331, p. 1, 2025.
- [2] Author, B. et al., "Hierarchical Context-Aware Summarization for Complex Korean Administrative Tables via Multi-Stage Prompt Engineering", Preprints:202602.2053, p. 3, 2026.
- [3] Author, C. et al., "LLM on a Budget: Active Knowledge Distillation for Efficient Classification of Large Text Corpora", arXiv:2511.11574, p. 2, 2025.

- [4] Team, G. et al., "Gemma 2: Improving Open Language Models at a Practical Size", arXiv:2408.00118, p. 5, 2024.
- [5] Author, D. et al., "Learning with Less: Knowledge Distillation from Large Language Models via Unlabeled Data", arXiv:2411.08028, p. 1, 2024.
- [6] Author, E. et al., "KD-LoRA: A Hybrid Approach to Efficient Fine-Tuning with LoRA and Knowledge Distillation", arXiv:2410.20777, p. 4, 2024.